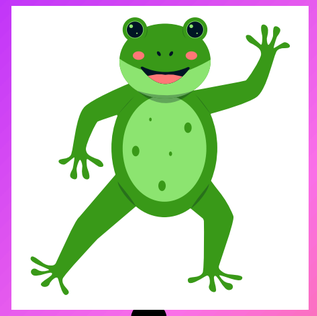

Lenguaje natural

Minería de datos

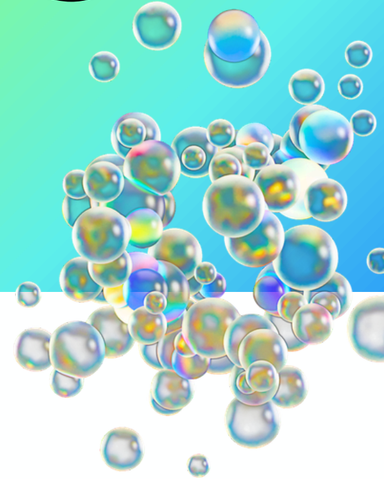

Emiliano Gonzalez | Andrea Moran | Ximena Vargas
Cristobal Coronado | Luis Vargas

Fig. 1. Vector representation of document space.

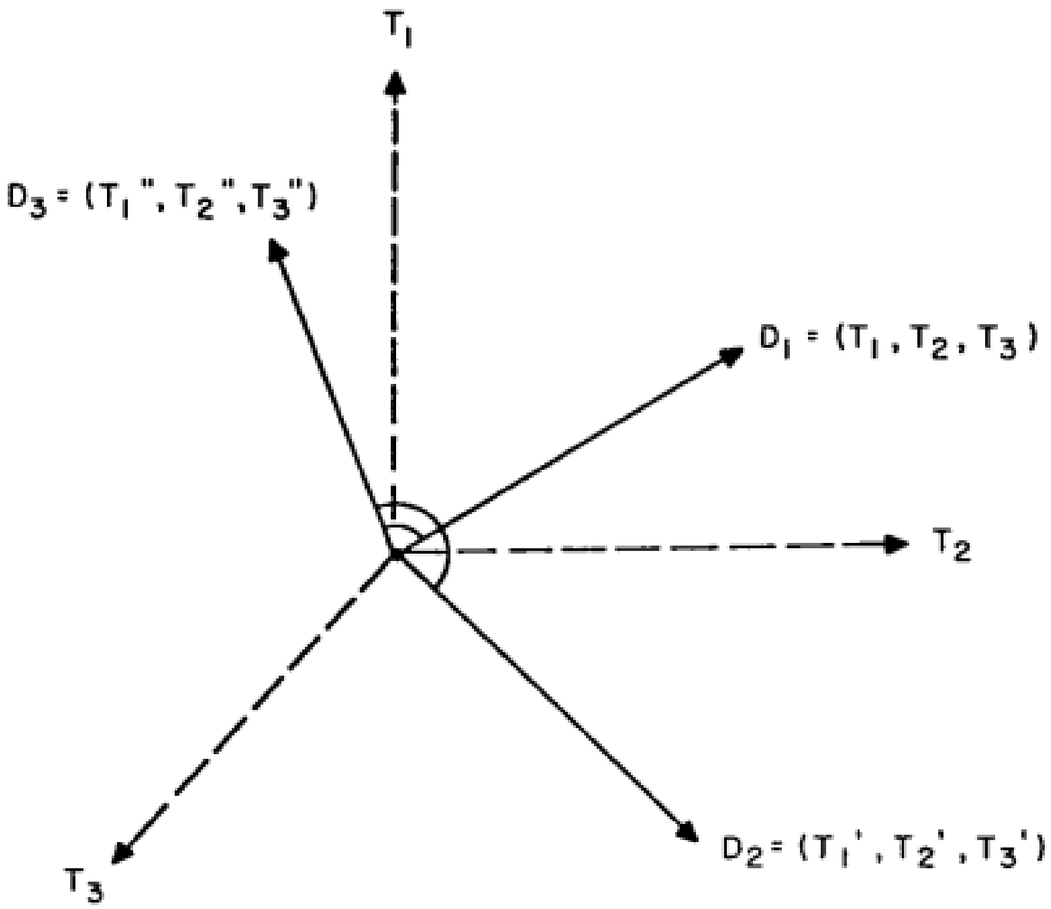

Fig. 2. Ideal document space.

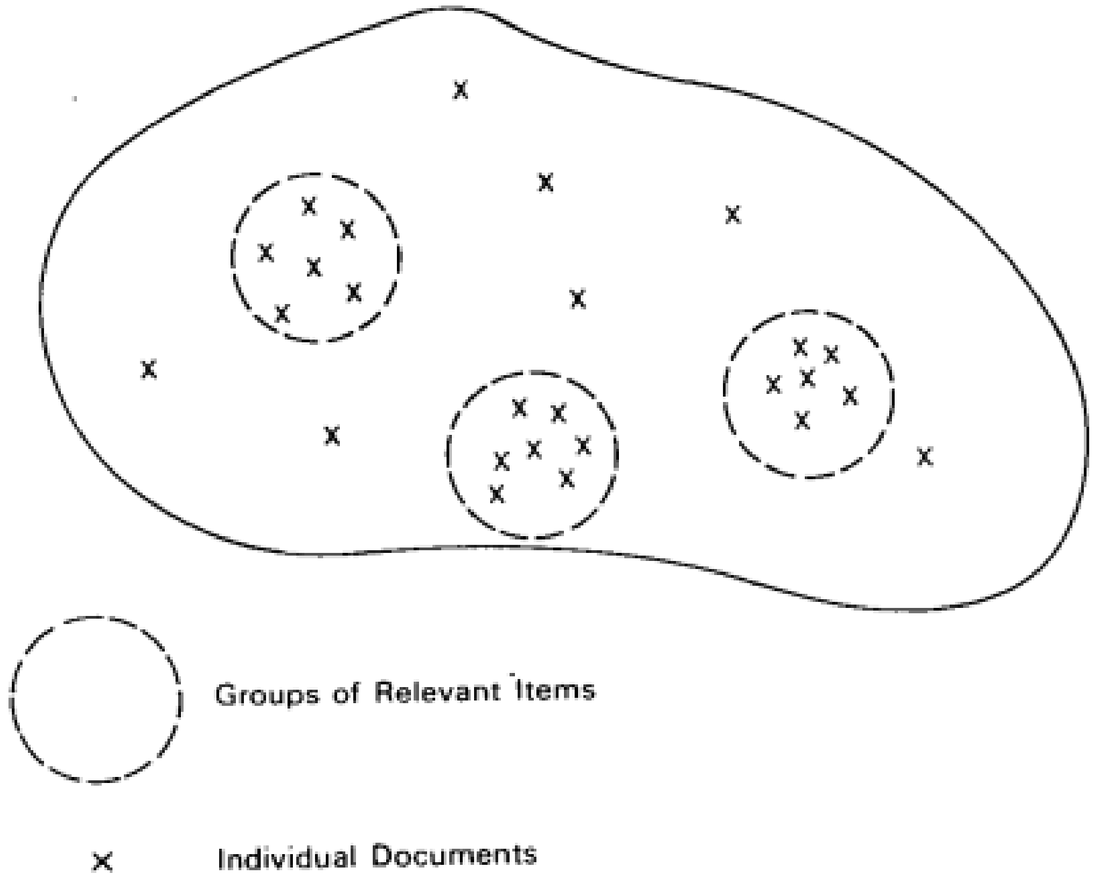

Fig. 3. Space with maximum separation between document pairs.

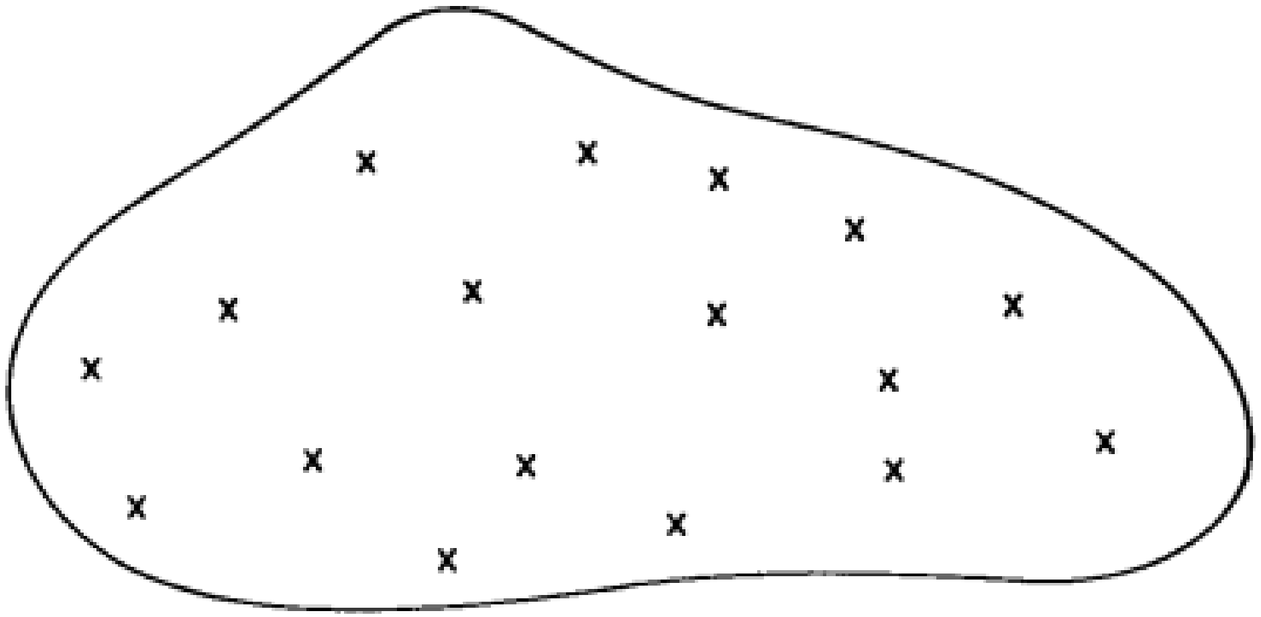

× Individual Document

Fig. 4. Clustered document space.

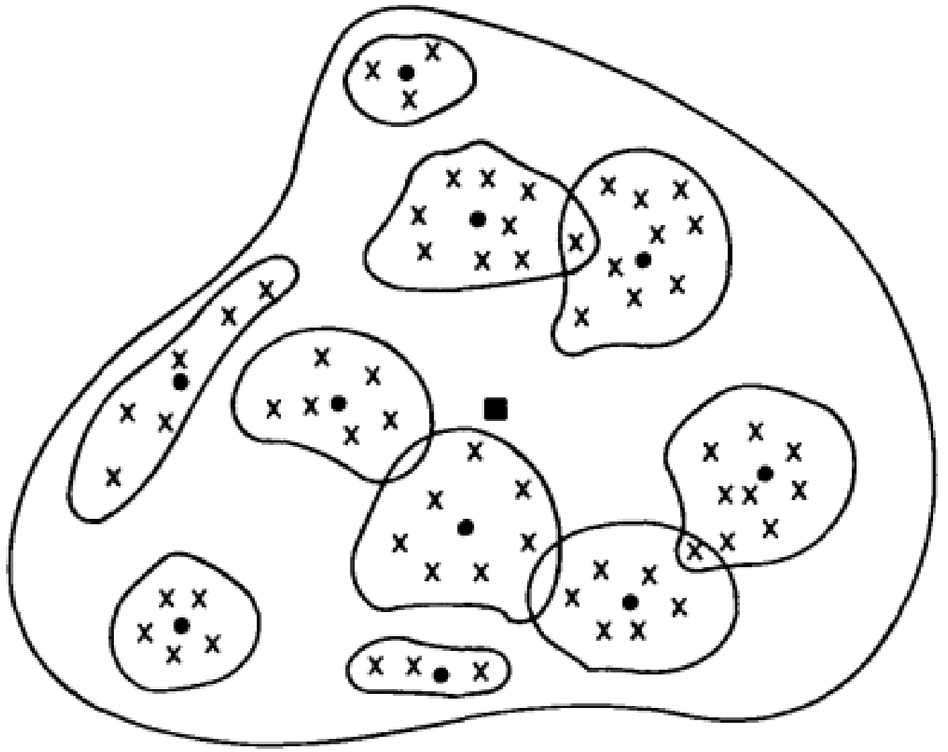

● Cluster Centroid

■ Main centroid

Correlación indexing performance y space density

Space Density e Indexing Performance

- La **densidad espacial** indica qué tan concentrados están los documentos en el espacio de representación.
- El **indexing performance** se relaciona con qué tan bien el sistema puede recuperar información relevante.

¿Qué es Space Density?

- **Alta densidad**: los documentos están muy juntos.
- **Baja densidad**: los documentos están más separados.

Correlación indexing performance y space density

Al expandir el espacio:

- Aumentaron la similitud entre documentos del mismo grupo.
- Disminuyeron la similitud entre grupos diferentes.
- La densidad disminuyó.
- El desempeño mejoró algunos puntos porcentuales.

Al comprimir el espacio:

- Disminuyó la similitud dentro de los grupos.
- Aumentó la similitud entre grupos diferentes.
- La densidad aumentó.
- Se observaron pérdidas de aproximadamente 12–13% en recall y precision en los casos estudiados.

Correlación indexing performance y space density

Mayor Space Density
- documentos más concentrados
- más difícil diferenciarlos
- puede disminuir el desempeño

Menor Space Density
- documentos más separados
- mayor diferenciación
- puede mejorar el desempeño

Resumen

La space density tiene una relación importante con el desempeño de la indexación. Los experimentos del artículo apoyan esta relación al mostrar mejores resultados al expandir el espacio y pérdidas de desempeño al comprimirlo. Cuando los documentos están menos concentrados, es más fácil diferenciarlos entre sí y recuperar la información relevante. Por eso, la distribución de los documentos dentro del espacio de representación es importante para el funcionamiento del sistema.

The discrimination Value Model

En esta sección, se toma en cuenta el valor de discriminación (DV), el cual mide la capacidad para aumentar la separación y las diferencias entre los vectores de los documentos.

Relación con la frecuencia de palabras

Thanks for your Attention

Slides Carnival

for this presentation template

Pexels, Pixabay, Sketchify

for the photos, graphics, and elements

Happy designing!